

Semestrální projekt PAR 2009/2010:

Paralelní algoritmus pro řešení problému bipartitního podgrafu

Petr Smejkal
David Vavrousek

5. ročník, obor počítače, K336 FEL CVUT, Karlovo nám. 13, 121 35 Praha 2

May 10, 2010

1 Definice problému a popis sekvencního algoritmu

1.1 Definice problému BPG: bipartitní podgraf

1.1.1 Vstupní data

n = přirozené číslo představující počet uzlů grafu, $n \geq 5$

k = přirozené číslo řádu jednotek představující maximální stupeň uzlů grafu

$G(V, E)$ = jednoduchý neorientovaný neohodnocený souvislý graf o n uzlech a stupni nejvýše k

Doporučení pro algoritmus generování G :

Použijte generator grafu Generator1 s typem grafu "t 1", který vygeneruje souvislý neorientovaný neohodnocený graf.

1.1.2 Definice

Graf $G(V, E)$ je bipartitní jestliže můžeme rozdělit množinu uzlů na disjunktní množiny U a W tak, že každá hrana v G spojuje uzel z U s uzlem z W . Bipartitní graf je možné uzly obarvit 2 barvami.

1.1.3 Úkol

Graf $G(V, E)$ je definován množinou uzlů V a množinou hran E . Úkolem je najít maximální podmnožinu hran F takovou, že graf $G(V, F)$ je bipartitní (viz obrázek).

1.2 Popis sekvencního algoritmu

Základním algoritmem bylo procházení stavového prostoru do hloubky. Hloubka stavového stromu je omezena na $|E|$. Pro reprezentaci stavu jsme si vytvořili třídu State, která obsahuje matici sousednosti grafu. Přípustný mezistav je podmnožina hran F , která tvoří bipartitní podgraf $G(V, F)$. Cílem, kterému maximalizujeme, je počet hran v F . Pokud je graf G bipartitní, pak triviálně $F=E$, jinak F je podmnožinou E . Vstupní graf nejprve otestujeme, zda je bipartitní (lineární algoritmus) a pokud ne, použijeme algoritmus prohledávání do hloubky. Základní myšlenkou algoritmu je postupné odebírání hran. Na zásobník se vloží počáteční stav, reprezentující zadaný graf. Dale se postupuje podle algoritmu prohledávání do hloubky, při expanzi se na zásobník vloží 2 nové stavy, jeden s hranou n a jeden bez ní. Celkový počet hran n určuje maximální hloubku stromu reprezentujícího graf stavového prostoru. Pro ořezávání stavového prostoru využíváme techniky branch and bounds, celý algoritmus je tedy DFS-BB. Jedná se o úplné prohledávání stavového prostoru do hloubky $|E|-|V|$. Prohledávání se může navracet v mezistavech s $|F|=|V|-1$ (strom je triviálně bipartitní, proto musí existovat řešení s $|F|=|V|-1$). Triviální dolní mez je $|F|=|V|-1$. Tesná horní mez není známa. Triviální horní mez je $|F|=|E|$.

Uveďte tabulku naměřených časů sekvencního algoritmu pro různé velikosti dat.

2 Popis paralelního algoritmu a jeho implementace v MPI

Základem paralelního algoritmu je sekvencní algoritmus. S tím rozdílem, že stavový prostor se disjunktně rozdělí mezi více procesorů, které ho samostatně zpracovávají. Kvůli omezujícím podmínkám algoritmu DFS-BB si procesory mezi sebou posílají nalezená nová nejlepší řešení. Jednotlivé procesory mají svůj vlastní lokální zásobník a používá se dynamické vyvazování výpočetní zátěže (load balancing). Vyvazování zátěže je implementováno pomocí 2 algoritmu: algoritmu pro dělení zásobníku (ADZ) a algoritmu pro hledání darce

(AHD), kterými necinný procesor s prázdným lokálním zásobníkem (stav $I=idle$) získává práci od vhodného darce, což je aktivní procesor s neprázdným zásobníkem (stav $A=active$), jehož zásobník odpovídá dostatečně velkému stavovému podprostoru. Procesor si o práci žádá procesor s číslem o jedno větší, pokud ten práci nemá, zvýší se citací o jedničku, takto cyklicky žádá procesory dokud neobdrží práci nebo požadavek na ukončení. Na počátku procesor P_1 zná počet procesorů p , na kterých se úloha bude řešit. Provede dostatečný počet expanzí počátečního stavu, rozdelí svůj zásobník na p částí a rozesle jednotlivé části ostatním procesorům. Všechny procesory začnou prohledávat svůj přidělený podprostor a přitom realizují programovou smyčku naznačenou na tomto obrázku.

OBRÁZEK

Aktivní procesor, který vycerpa svůj přidělený díl práce, se stane necinný a pomocí algoritmu pro hledání darce AHD vybere darce a pošle mu žádost o práci. Pokud mu darce práci pošle, přepne se zpět do stavu aktivní. Pokud se mu vrátí odmítnutí, vše se opakuje. Procesor ve stavu necinný musí také periodicky kontrolovat, zda nemá ve frontě žádosti o práci, na které odpovídá odmítnutím, nebo zprávy o nalezení řešení jiným procesorem. V případě, že se jedná o optimální řešení, jsou to v podstatě žádosti o ukončení výpočtu. Aktivní procesor provádí fixní objem práce nad lokálním zásobníkem (expanduje určitý daný počet stavů na lokálním zásobníku) a pak kontroluje frontu zpráv. V té mohou být žádosti o práci, informace o nalezení řešení jiným procesorem a žádosti o ukončení výpočtu. Aktivní procesor zpracovává žádosti o práci následujícím způsobem: Pokud je velikost lokálního zásobníku větší než nastavená minimální mez, tak se zásobník rozdelí a část se zasle zadateli o práci. Zjistí počet žádostí ve frontě. Necht je jich $k_L=1$. Pak algoritmem ADZ rozdelí svůj zásobník na $k+1$ částí a k částí rozesle k zadatelům. Sam pak pokračuje ve výpočtu se zbytkem zásobníku. Pokud má sám nebo by mu zbylo jen podpráhové množství práce (položky zásobníku nad prahem rezne výsky), část požadavku nebo všechny požadavky odmítne.

Popíšte paralelní algoritmus, opět vyjdete ze zadání a přesně vymezte odchylky, zvláště u algoritmu pro vyvazování zátěže, hledání darce, či ukončení výpočtu. Popíšte a vysvětlete strukturu celkového paralelního algoritmu na úrovni procesů v MPI a strukturu kódu jednotlivých procesů. Např. jak je naimplementována smyčka pro činnost procesu v aktivním stavu i v stavu necinnosti. Jaké jste zvolili konstanty a parametry pro skalování algoritmu. Struktura a semantika příkazové řádky pro spouštění programu.

3 Analýza složitosti paralelního řešení

Pokuste se analyticky stanovit očekávanou složitost vašeho řešení: paralelní čas, práce, náklady, zrychlení, efektivnost, ap. Odhadněte optimální granularitu, tj., stupeň paralelismu pro danou velikost řešeného problému. Stanovte kritéria pro stanovení meze, za kterými již není účinné rozkládat výpočet na menší procesy, protože by komunikační náklady převážily urychlení paralelním výpočtem.

4 Naměřené výsledky a vyhodnocení

1. Zvolte více instancí problému s takovou velikostí vstupních dat, pro které má sekvencní algoritmus časovou složitost řádu nejméně jednotek minut a nejvýše několik málo hodin. Pro měření času potřebný na čtení dat z disku a uložení na disk neuvazujte a zakomentujte ladici tisky, zprávy a výstupy.
2. Měřte paralelní čas při použití $i = 2, \dots, 16$ procesů.
3. Při měření každé instance problému na daný počet procesorů spočítejte pro váš algoritmus dynamické delby práce celkový počet odeslaných žádostí o práci, průměr na 1 procesor a jejich úspěšnost.
4. Měření pro daný počet procesorů a instancí problému proveďte 3x a použijte průměrné hodnoty.
5. Z naměřených dat sestavte grafy zrychlení $S(n, p)$. Zjistete, zda a za jakých podmínek došlo k superlineárnímu zrychlení a pokuste se je zdůvodnit.
6. Vyhodnoďte komunikační složitost dynamického vyvazování zátěže a posuďte vhodnost vami implementovaného algoritmu pro hledání darce a dělení zásobníku při řešení vašeho problému. Posuďte efektivnost a skalovatelnost algoritmu. Popíšte nedostatky vaší implementace a navrhněte zlepšení.

5 Literatura

A Navod pro vkladani grafu a obrazku do Texu

Nejjednodussi zpusob vytvoreni obrazku je pouzit sunovsky graficky editor xfig, ze ktrereho lze exportovat latex formaty (v poradi prosty latex, latex s macry epic, eepic, eepicemu) a postscript formaty, uvedene poradi odpovida rustu komplikovanosti obrazku (postscript umi jakykoliv obrazek, prosta latex macra pouze jednoduche, epic makra neco mezi, je treba vyzkouset). Nasleduji priklady pro vsechny pripady.

Obrazek v postscriptu, vycentrovany a na celou sirku stranky, s popisem a cislem. Vsimnete si, jak ridit velikost obrazku.

Figure 1: Popis vaseho obrazku

Obrazek pouze vlozeny mezi radky textu, bez popisu a cislovani.

Texovske obrazky maji pripony *.latex, *.epic, *.eepic, a *.eepicemu, respective. Vypustenim zavorek **figure**




Figure 2: Popis vaseho obrazku

dostanete opet pouze ramecek v textu bez cisla a popisu.

Takhle jednoduse muzete poskladat obrazky vedle sebe.



Ridit velikost texovskych obrazku lze prikazem

```
\setlength{\unitlength}{0.1mm}
```

ktre meni meritko rastru obrazku, Tyto prikazy je ale soucasne nutne vyhodit ze souboru, který xfig vygeneroval.

Pro vytvoreni grafu lze pouzit program gnuplot, který umi generovat postscriptovy soubor, který vlozite do Texu vyse uvedenym zpusobem.